



สถาปัตยกรรมธรรมาภิบาล AI ใหม่


การจัดสรรอำนาจตัดสินใจและความรับผิดชอบแบบพลวัตภายใต้ความไม่แน่นอน



สิ่งที่เราไม่ต้องการเพิ่ม



องค์ประกอบที่ขาดหายไป




**ปัญหาใหม่ที่กำลังท้าทายคือการจัดสรรอำนาจตัดสินใจ และความรับผิดชอบในระบบ AI แบบประกอบ
อย่างเป็นพลวัต**


➡ ตัวควบคุมต้องกำหนดได้ว่า: ใครมีอำนาจดำเนินการ? หลักฐานใดเพียงพอ? การกระทำนั้นย้อนกลับได้หรือไม่? และใครคือผู้รับผิดชอบ?

ช่องว่างการวิจัย

งานวิจัยปัจจุบัน



เป้าหมาย: ระบบ AI ที่ทำงาน
ร่วมกันหลายขั้นตอน
(Composed AI Workflows)




การบังคับใช้เชิงปฏิบัติการ

งานวิจัยปัจจุบันครอบคลุมการจัดการกำกับ
ดูแลและความรับผิดชอบเชิงสาเหตุแล้ว

ช่องว่างที่แท้จริงคือสะพานเชื่อมแนวคิดเหล่านี้
สู่การตัดสินใจที่สามารถบังคับใช้และย้อนกลับได้
ในกระบวนการทำงานจริง

สถาปัตยกรรม RACER


Reversibility- and Accountability-Constrained Execution Regulator



RACER ไม่ใช่โมเดลที่พยายามอนุมานสถานะ Alignment ที่ซ่อนอยู่ แต่เป็น Control-plane ที่กำกับดูแลผ่านสัญญาข้อมูลที่ชัดเจน

องค์ประกอบของ Action Packet: เวกเตอร์ $z_t(a)$


ทุกการกระทำที่ถูกเสนอจะถูกแปลงเป็นแพ็คเกจข้อมูลเพื่อการประเมินแบบองค์รวม



คณิตศาสตร์แห่งธรรมชาติ: การคำนวณการขาดแคลนอำนาจ


$$D_A(a, t) = [r_t u_t b_t (1 - q_t) / (e_t h_t)]_+$$

ค่า D_A ที่สูงหมายความว่าระบบกำลังพยายามกระทำการที่ความเสี่ยงและความไม่แน่นอนมีน้ำหนัก "เกินกว่า" หลักฐานและอำนาจรับผิดชอบที่มีอยู่



D_A ไม่ใช่คะแนนศีลธรรมสากล แต่เป็นตัวแปรควบคุมเชิงนโยบาย ที่ต้องผ่านการทดสอบเชิงประจักษ์

การหาจุดปฏิบัติการธรรมาภิบาลที่เหมาะสม




$$g^*(a, t) = \operatorname{argmin}_g C(g) + \lambda D_A(a, t) + \mu L(g, a)$$

เงื่อนไขข้อจำกัด (Constraints):

- $P(\text{unsafe} \mid z_t, g) \leq \epsilon$ (อยู่ในขีดจำกัดความปลอดภัย)
- $P(\text{recovery} \mid g, a) \geq \rho$ (รับประกันความสามารถในการฟื้นฟู)
- $E[\text{utility} \mid g, a] \geq U_{\min}$ (รักษาอรรถประโยชน์ขั้นต่ำ)

กลไกหลัก: การยกระดับอำนาจตามความสามารถย้อนกลับได้



ระบบจะมอบความเป็นอิสระ ก็ต่อเมื่อหลักฐาน ความไม่แน่นอน ความสามารถในการย้อนกลับ และอำนาจรับผิดชอบ มีความเพียงพอร่วมกัน (Jointly sufficient)

การประเมินความแตกต่าง

เป้าหมายหลักของ RACER คือการควบคุมการทำงานที่รักษาสถานะความรับผิดชอบ ไม่ใช่แค่การตรวจจับ

	ตัวกรองความ ปลอดภัยแบบขาวดำ	การคัดกรองตาม ความเสี่ยง	KOTA/ ShadowPipeline	RACER
การยกระดับแบบพลวัต	✗	✗	✗	✓
การตระหนักถึง การย้อนกลับ	✗	✗	✗	✓
การติดตามความ รับผิดชอบเชิงสาเหตุ	✗	✗	✗	✓
เป้าหมายหลัก	การตรวจจับ/ การบันทึก	การตรวจจับ/ การบันทึก	การตรวจจับ/ การบันทึก	การเลือกจุดปฏิบัติ การธรรมาภิบาล

ข้อกำหนดสำหรับการตรวจสอบสมมติฐาน และบทสรุป

ต้องใช้ข้อมูลเวิร์กโฟลว์จริง ไม่ใช่แค่การจำลองทางคณิตศาสตร์

ต้องแสดงให้เห็นถึงการลดลงของความล้มเหลวที่ย้อนกลับไม่ได้

ต้องใช้ภาระการกำกับดูแลที่ต่ำกว่าระบบเดิม

ความแปลกใหม่ที่แท้จริงคือการ
สังเคราะห์เชิงปฏิบัติการ ให้
กลายเป็นตัวควบคุมธรรมชาติที่
ย้อนกลับได้ และ
ถูกจำกัดด้วยหลักฐาน โดย
มีการติดตามความรับผิดชอบ
เชิงสาเหตุที่วัดผลได้